



MBA - Engenharia de Dados

MAPEANDO A DESIGUALDADE

**Assimetrias Socioeconômicas nos Municípios
Brasileiros via ENEM 2024**

- Felipe Araujo - RA 10732144
- Felipe Lage - RA 10731861
- Lucas Oliveira - RA 10732279
- Martin Heib - RA 10734895





*Por trás de cada nota no ENEM
existe uma realidade social. Como
algoritmos de dados podem ajudar
o Brasil a identificar e priorizar os
municípios com maior
vulnerabilidade educacional?*

Os números da desigualdade

168 PONTOS

É a média que separa alunos do topo e da base da pirâmide segundo dados históricos do ENEM / INEP .

23X MAIS

Candidatos pertencentes à faixa de renda familiar mais alta têm até 23 vezes maior de atingir nota máxima na redação aos candidatos de famílias de baixa renda.

74%

Dos alunos de municípios mais vulneráveis dependem do celular ou não possuem acesso à internet.

Fonte: INEP e IBGE

O(S) PROBLEMA(S)

ABISMOS MUNICIPAIS:

O Brasil possui mais de 5.500 municípios com realidades socioeducacionais gigantescas e discrepantes.

POLÍTICAS GENÉRICAS

Investimentos públicos e ações educacionais costumam ser distribuídos de forma padronizada, ignorando as carências críticas de cada região.

FALTA DE DIAGNÓSTICO:

Inexistência de uma visão clara e agrupada que correlacione o desempenho escolar diretamente aos fatores locais (renda, internet, escolaridade dos pais).

CONSEQUÊNCIA:

Sem identificar quais variáveis geram os piores gargalos por cidade, a alocação de recursos se torna ineficiente, perpetuando a desigualdade.



Sobre os dados

Bases utilizadas	Tamanho	Formato	Linhas	Colunas
Participantes_2024	451 MB	.csv	4.3 Mi	38
Resultados_2024	2 GB	.csv	4.3 Mi	42

Tratamento da base

- Otimizando a Base removendo colunas desnecessárias

```
# 1. Escopo de Participantes
colunas_part_oficial = [
    'CO_MUNICIPIO_PROVA', 'NO_MUNICIPIO_PROVA', 'CO_UF_PROVA', 'SG_UF_PROVA',
    'TP_FAIXA_ETARIA', 'TP_SEXO', 'TP_COR_RACA', 'TP_ST_CONCLUSAO',
    'Q001', 'Q002', 'Q003', 'Q004', 'Q005', 'Q006', 'Q007', 'Q008', 'Q009', 'Q010',
    'Q011', 'Q012', 'Q013', 'Q015', 'Q016', 'Q018', 'Q020', 'Q021',
    'Q022', 'Q023'
]

# 2. Escopo de Resultados
# - Removemos todas as colunas _ESC (Escola) que geravam 2.7M de nulos.
# - Devolvemos TP_PRESENCA_MT para ser o nosso "marcador oficial" de abstenção.
colunas_res_oficial = [
    'NU_SEQUENCIAL', 'NU_ANO', 'CO_MUNICIPIO_PROVA', 'NO_MUNICIPIO_PROVA',
    'CO_UF_PROVA', 'SG_UF_PROVA', 'TP_PRESENCA_MT', 'NU_NOTA_CN', 'NU_NOTA_CH',
    'NU_NOTA_LC', 'NU_NOTA_MT', 'TP_STATUS_REDACAO', 'NU_NOTA_COMP1',
    'NU_NOTA_COMP2', 'NU_NOTA_COMP3', 'NU_NOTA_COMP4', 'NU_NOTA_COMP5', 'NU_NOTA_REDACAO'
]

# 3. Alocação de Memória (Criando os DataFrames enxutos)
df_part_limpo = df_participantes[colunas_part_oficial].copy()
df_res_limpo = df_resultados[colunas_res_oficial].copy()
```

```
>>> NULOS EM RESULTADOS <<<
(Nota: Nulos em NU_NOTA_... são e
```

```
0
```

```
NU_NOTA_MT    1327963
```

```
NU_NOTA_CN    1327963
```

```
NU_NOTA_LC    1164989
```

```
NU_NOTA_COMP5 1164989
```

```
NU_NOTA_COMP4 1164989
```

```
dtype: int64
```


- A diferença de 160 mil nulos entre os dias reflete a evasão entre o primeiro e o segundo domingo de prova.

PERFIL DEMOGRÁFICO E DISTRIBUIÇÃO GEOGRÁFICA (ENEM 2024)

Análise detalhada dos inscritos por sexo, situação do ensino médio, e as principais regiões (Estados e Municípios) de origem dos candidatos.




Inscritos por Sexo




- Feminino**
2.624.617 (60,6%)
- Masculino**
1.708.316 (39,4%)




Situação do Ensino Médio



Top 10 Estados (UF)



Top 10 Municípios



Análise comparativa completa de todos os estratos de **Escolaridade** e **Ocupação Profissional** entre pais (homens) e mães (mulheres).

Pai / Homem Mãe / Mulher



Nível de Escolaridade



Grupos de Ocupação Profissional



Fonte: INEP e IBGE

Apesar de possuírem maior nível de escolaridade **(23,5% com Ensino Superior contra 15,6% dos pais)**, as mães sofrem com a precarização do mercado de trabalho. **40%** delas estão concentradas no Grupo 2 (Diaristas, Vendedoras), serviços de menor remuneração.

A imensa maioria dos candidatos pertence a classes populares. A elite profissional (Grupo 5 - Médicos, Engenheiros, Diretores) representa uma **minoria esmagadora** (7,1% dos pais e 5,4% das mães), evidenciando o perfil socioeconômico de quem busca o ENEM.

Profissões ligadas a trabalho braçal, rural e mecânico (Grupos 1 e 3) são esmagadoramente dominadas por homens **(41,3% dos pais contra 21,6% das mães)**. Além disso, pais apresentam maior taxa de abandono escolar precoce e analfabetismo.

BENS DURÁVEIS E ACESSO TECNOLÓGICO (ENEM 2024)


Análise das condições materiais e digitais dos domicílios dos inscritos, contrastando itens básicos e de tecnologia da informação.



Internet Wi-Fi (Q020)




Computador/Notebook (Q021)




Aparelho de TV (Q018)




Geladeira (Q013)



Máquina de Lavar (Q015)



Micro-ondas (Q016)




DESEMPENHO GERAL E O CUSTO DA EXCLUSÃO DIGITAL (ENEM 2024)


Análise das médias gerais dos municípios (Top 10 Melhores vs. Piores) e o impacto direto da extrema exclusão digital no desempenho das provas.




Top 10 Maiores Médias Gerais



Top 10 Menores Médias Gerais



Média Nacional Extrema Exclusão Digital



Extração de
microdados do
INEP




Bronze (LANDING)	Silver (PROCESSAMENTO)	Gold (ANALYTICS)
• Sem Tratamento nos arquivos • Preservação dos dados originais	• Limpeza de Nulos • Join das Bases a partir da cidade da Prova/Aluno	• Agregação das Bases. • Tratamento das variáveis Escolhidas • Reconhecimento de padrões e tendências • Machine Learning

Ferramentas



mongoDB®



Algoritmos de Clusterização

A clusterização foi aplicada para agrupar os mais de 5.500 municípios brasileiros em perfis semelhantes, transformando dados socioeconômicos complexos em alvos claros para políticas públicas.

K-Means

Alta eficiência em grandes volumes.

Algoritmo simples e muito rápido.

Funciona bem na maioria dos casos.

K-Medoids


Robusto contra outliers.

Centroide é uma cidade real.

Ideal para criar grupos bem definidos.


Nota X Renda

- Existe uma relação negativa clara: maior pobreza resulta em menor desempenho acadêmico.
- Os municípios agrupam-se em quatro níveis de vulnerabilidade/desempenho
- O Grupo 3 (alta vulnerabilidade e baixo desempenho) exige intervenção pública imediata.




Cluster Crítico

- O Amazonas (AM) concentra o maior número de municípios no cluster crítico, totalizando 47 cidades..
- Os municípios agrupam-se em quatro níveis de vulnerabilidade/desempenho
- Os 3 primeiros estados concentram a maioria absoluta dos municípios em situação de vulnerabilidade, evidenciando que a prioridade de intervenção está concentrada em uma parcela pequena dos estados



Métricas de Acurácia

- Considerando ambas as métricas de validação de clustering, o K-Means apresentou resultados superiores ao K-Medoids em todos os critérios avaliados.



```


=====
AUDITORIA DE MODELO: K-MEDOIDS E DECISÃO FINAL
=====

>>> MATRIZ DE VALIDAÇÃO DE MODELOS (PERFORMANCE DE CLUSTERING) <<<

```


	Métrica	Alvo Ideal	K-Means	K-Medoids
0	Silhouette Score	Maior é Melhor	0.3901	0.3342
1	Davies-Bouldin	Menor é Melhor	0.8688	1.0425

Considerações finais




APRENDIZADO

Considerar outliers é vital, pois municípios extremos distorcem médias e geram falsos diagnósticos.



FUNCIONOU


A análise exploratória possibilitou a escolha assertiva das variáveis utilizadas no ML.



OPORTUNIDADES


A utilização inicial de repositórios online e gratuitos limitou a preservação dos dados e criação das camadas. As métricas de acurácia foram abaixo do esperado.

Considerações finais




INSIGHTS

O cruzamento de dados evidenciou que desigualdade no ENEM gera uma barreira geracional de infraestrutura.



IMPACTO

Direcionar políticas públicas à municípios com barreiras estruturais, transformando dados em ações concretas de inclusão.



PARA O FUTURO

Aplicar modelo em anos anteriores e comparar o comportamento dos cluster ao longo do tempo.

Avaliar com mais detalhes o peso de cada variável na nota de cada estado.

Muito Obrigado!



FELIPE ARAUJO

Date Engineer



FELIPE WAGNER

Commercial Filings & Documentation Sr.
Analyst



LUCAS OLIVEIRA

Associate MIS Analyst



MARTIN HEIB

Customer Service Analyst